重新思考扩散桥医学图像翻译中的不确定性量化：

陷阱、基线与边界 （系统：TrustBridge——含收敛残差场的免训练信任层）

代码与权重：https://github.com/ASHDUSK/TrustBridge-

2026 年 11 月

ABSTRACT

两个隐蔽的陷阱正在腐蚀医学图像翻译领域大多数不确定性量化（UQ）主张。其一，*背景空气像素*： 空气区域"高信任、近零误差"，混入整图统计后会成倍虚高 UQ 指标——我们展示同一信号的头条定位分数 在体掩码口径下从 0.90 崩落到 0.78，并撤回了自己早期受益于此的数字。其二，*分歧不等于误差*： 在与 TTA、输入噪声基线的等预算对比中，所有分歧类信号——包括我们的——在残差误差由细纹理主导的 T2→T1 官方权重上均接近随机水平（部分系统性偏低）。那么，什么*能够幸存*？从自洽递归扩散桥采样器 （SelfRDB）中我们收割两类免训练信号：*收敛残差场*（CReF，采样器本来就在计算却丢弃的 相邻递归目标估计逐像素差异）与*随机桥集成不确定性*。融合为逐像素信任图后，在体掩码口径下它们给出：AUROC 0.90（T1→T2 自训）与 0.82 （T2→T1 自训），超过全部等预算基线，单链零额外成本即达 $0.88/0.79$；在 BraTS2018 的 6 名肿瘤患者中，信任图对体区内高误差像素的定位 AUROC 为 0.911（切片级 95% CI $[0.89, 0.93]$），但对肿瘤组织本身无定位能力（0.51）。6 名 CBICA 受试者的初步外部验证切片级 AUROC 为 0.950。CReF 触发的路由在自训模型上无增益—— 进一步确认信号排序的模型相关性。专门的复现性分析解释了官方权重为何在独立制备数据上崩塌至 $\sim$15 dB（论文值 31.56 dB）——是结构性的而不仅是光度的（NCC 0.41）——并表明信任层 *未能察觉*：崩塌模型获得 PASS 与 $94/100$ 的平均信任。自洽性无法证明正确性， 外部验证不可替代。我们发布全部阴性结果——口径陷阱、纹理主导失效边界、肿瘤定位缺位、 图像级门控失准——作为给领域的边界地图，并建议图像翻译的 UQ 主张一律在体区内、 对照廉价基线、按（模型, 方向）逐一评估。

1. 引言

多对比度磁共振成像（MRI）提供互补的组织对比信息，但临床上采集全部相关加权既昂贵、缓慢， 有时还存在禁忌。医学图像翻译——从已采集模态合成未采集模态——正是为解决这种稀缺性而生， 且保真度已经很高。去噪扩散概率模型（DDPM）[1,2] 以训练稳定 取代了 GAN 在该任务的地位，扩散桥则不经过各向同性噪声瓶颈、直接连接源与目标分布。 其中 SelfRDB[3] 提出自洽递归扩散桥，达到最先进的多对比度翻译水平。 然而，信任没有跟上保真度。由于翻译是病态问题，生成模型会*幻觉*：合成出解剖中不存在 但看起来合理的结构。临床使用中，放射科医生无法区分这类编造与忠实合成——这一信任瓶颈 （而非图像质量）才是部署的主要障碍。SelfRDB 作者明确指出这一缺口：扩散桥的不确定性 "值得在未来工作中评估"[3]。 我们用一个观察来填补它：自洽递归采样器在每一步、每个像素上都在计算评估自身

可靠性所需的 证据——只是把它丢弃了。SelfRDB 把相邻递归估计的差异压缩为单个停机标量；而逐像素残差场 *承载着模型无法自洽*的空间分布。同样，桥终点噪声与生成器隐变量使重复采样彼此不同， 其分歧标记了模型没有稳定信念的位置。TrustBridge 把两类信号系统化为逐像素信任图，并检验其图像级聚合的可行性（§4.6）与能力边界（§4.2、§4.8），具备三条区别于既有不确定性机制的性质： (i) *免训练*——不改模型、不要标注、不加网络；(ii) *采样器原生*——信号提取自 采样器本来就在计算的量；(iii) *像素级*——不同于图像级幻觉指标[4]，输出支持放射科医生的局部阅读。 第三条贡献是方法学的。在验证过程中我们发现，*背景空气像素会悄悄虚高整图信任指标*： 空气"可信"且近乎零误差，与体像素混合统计后，任何"低信任预测高误差"的分数都被美化。 我们最初报告的若干数字（肿瘤定位 AUROC 0.87、十分位分离 35–$73\times$）即属此类伪影， 在体区口径下不复存在。本文所有信任指标一律在体掩码内计算，并把这轮撤回的完整轨迹 （docs/18 与修正脚本）作为方法论证据发表。

贡献：

1. 我们提出*收敛残差场（CReF）*与随机桥集成不确定性作为扩散桥翻译的互补、 免训练、像素级的可信度证据，融合为信任图（§3）。
2. 我们提出体掩码评估协议，量化整图口径的虚高效应，并以等预算分散基线 （TTA、输入噪声）对照重评：自训模型上融合信号定位高误差十分位 AUROC $0.90/0.82$（T1$\rightarrow$T2/T2$\rightarrow$T1），超过全部基线；真实肿瘤患者 0.91、 跨机构 0.95；而*官方*权重上同一协议令排序反转、T2$\rightarrow$T1 全盲（§4）。
3. 我们报告七项边界实验（§4.7）与一项模型级失效——基座模型崩塌时信任层失明（§4.2）——结果为混合或阴性：自适应重采样、可学习聚合、图像级回归、强度调和、往返一致信号、官方权重 T2$\rightarrow$T1 信号失效、语义代理无互补。 并以此划定方法边界：分歧信号只在误差呈空间结构时有效，可学习聚合在 6 被试验证集上过拟合（§4、§5）。

2. 相关工作

2.1 医学图像翻译

非配对跨模态合成经历了从对抗式翻译的演进——CycleGAN[5] 与 pix2pix[6] 确立了非配对与配对两种范式，随后是多对比度 MRI 专精模型， 如条件 GAN[7] 与 CNN–Transformer 混合架构 （ResViT[8]）——再到扩散类模型。SynDiff[9] 以循环一致性先验的对抗式扩散实现无监督医学翻译；I2I-Galip[10] 用视觉–语言模型替换判别器以提升效率。平行地，扩散桥不经过各向同性噪声瓶颈， 而是直接连接源与目标两个图像分布：DDPM[1] 及其基于分数的推广[11] 提供了数学骨架，谱系中包括基于分数的 NCSN[12]、改进的调度[2]、 图像到图像薛定谔桥[13]、带数据一致性的直接扩散桥[14]、 对偶隐式桥[15]、神经薛定谔桥[16]、直接迭代反演[17] 以及三维桥理论[18]。SelfRDB[3] 将软先验桥与 自洽递归采样结合，报告了最先进性能。上述工作均以翻译质量为导向，不提供输出可信度信息。 **与之相对，本文在不改动翻译模型的前提下，从其推理过程内部提取可信度证据。**

2.2 医学影像不确定性量化

模型级方法包括 MC-Dropout[19]、深度集成[20] 与测试时增强[21]；不确定性可分为偶然性与认知性两类[22]。 扩散模型语境下，集成式不确定性已用于分割[23] 与 显微图像复原[24]：对同一输入采样多条链，以链间分歧度量困难区域。 本文继承该思路但有三点不同：(i) 我们的集成成员来自扩散桥自身原生的随机终点与隐变量， 无需注入额外随机性；(ii) 我们配对了一个与采样方差正交的免费信号——CReF， 它只存在于自洽递归采样器中；(iii) 我们将信号与临床 QC 场景对接，但图像级聚合被证明不可靠（§4.6），本文定位为像素级排序工具。 值得注意的是，部分桥模型将这种随机性当作缺陷主动抑制[25]； 本文论证：在可信度评估的任务里，它是资产。

2.3 生成影像的幻觉评估与可信放射 AI

与本文目标最接近的 Hallucination Index[4] 将生成式重建模型的编造内容量化为对重复采样计算的*图像级*指标； MUMINS[26] 以元数据为条件进行医学图像合成并训练不确定性感知 预测头输出空间不确定性图；[27] 的测量几何分析证明了测量算子 何时能够区分不同解，从算子设计视角解释幻觉。这些方法或需要图像粒度的重复采样， 或需要改动架构并重训，或需要事前的算子设计。TrustBridge 则在*现有采样器内部* 提取像素级证据，不需要架构改动或标注，并进一步支持规则化门控：我们的框架与 RAISE[28] 这类输出护栏生命周期互补，为 AI-RADS[29] 这类报告框架所呼唤的客观像素级证据提供供给， 同时保持全自动。

超越采样分歧：语义与病理感知信号。

分歧式证据对采样器*持续一致地犯*的错误是盲的——我们在 §4 量化了这一局限。 三条并行研究线从评估侧攻击该问题，并构成我们这类信任层的自然下一步。 CRAFT[30] 用基础模型的临床对齐分数（CAS）按临床标准为生成图像打分， 抑制幻觉样内容；ViCTr[31] 通过 EWC 正则的 LoRA 适配实现 分级严重度控制的病理感知合成；DDWM[32] 只学习目标域分布、 经小波分解融合域不变解剖，实现零样本翻译。三者或依赖基础模型、或需重训、 或需架构改动；它们与采样器原生证据互补，我们在 §6 展望中讨论。

方法对照。

表 1. 不确定性/幻觉评估方法对照（"额外前向"指相对单次基础推理的生成器前传次数）。 TrustBridge 一行的"无额外前传"限定于当前 SelfRDB 实现——其递归结构为常规 DDPM 所无。

方法	需要训练	额外模型	额外前向	输出粒度
MC-Dropout[19]	需（启用 dropout 重训）	否	多次	像素/图像
深度集成[20]	需（多模型）	是	多次	像素/图像
TTA[21]	否	否	多次	像素/图像
扩散集成[23,24]	否（复用模型）	否	多次	像素/图像
Hallucination Index[4]	视实现	视实现	多次	图像级
TrustBridge（本文）	否	否	**无额外**（单链）	像素级

3. 方法

3.1 预备：自洽递归扩散桥

SelfRDB[3] 构造的桥前向过程从目标图像 x_0 出发、终于加噪源图像 y_ϵ，中间样本 $x_t = \mu_{x_0,t}x_0 + \mu_{y,t}y + \sigma_t\epsilon$，其中 $\sigma_t^2 = \gamma s_t^2/(\bar{s}_t^2 + s_t^2)$ 单调增长（*软先验*）。反向采样自 $x_T = y_\epsilon$ 开始；每步 t 由生成器 $G_\theta(x_t, t, y, \tilde{x}_0^{(r)})$ 递归精炼 目标估计 $\tilde{x}_0^{(r+1)}$，直到相邻估计差异低于阈值 τ（SelfRDB 取全局均值 1%）， 随后以自洽估计 $\tilde{x}_0^*$ 驱动 x_{t-1} 的后验采样。公开配置为 $T{=}10$ 桥步、 至多 $R{=}2$ 层递归，单切片推理可交互。

3.2 收敛残差场（CReF）

每个反向步内，递归产生逐像素残差；SelfRDB 仅取其全局均值作停机判据并丢弃空间信息。我们保留捕获窗内各反向步的*末次递归残差*:

$$\mathrm{CReF}(p) \;=\; \frac{1}{K_0 \cdot N}\sum_{i=1}^{N}\sum_{t\in\mathcal{T}_i}\left|\tilde{x}_0^{(r_t,i)}(p) - \tilde{x}_0^{(r_t-1,i)}(p)\right|,$$

其中 $\mathcal{T}_i = \{t:\ t \le K_0,\ t \in \text{反向调度}\}$ 为链 i 实际捕获的桥步集合 （$K_0{=}3$ 为捕获窗的*时间步阈值*，与递归次数上限 $R_{\max}{=}2$ 是两个独立参数）， r_t 为该步实际执行的末次递归（自洽提前停机时取停机前残差），$\tilde{x}_0^{(0)} \equiv 0$； 分母为固定 K_0N——步长跳跃使实际捕获步数可少于 K_0，此差异如实保留而非调整分母 （公式与代码逐像素一致，经 4×4 极小输入人工核对）。直觉：生成器反复修正仍无法自洽的 像素，正是其学到的先验证据不足之处——幻觉候选区。我们将其准确定位为 *采样器内部收敛不稳定性的代理信号*：递归不收敛也可来自数值迭代或纹理敏感性， 并不严格等价于认知不确定性[22]。该信号不需要任何额外生成器 前传（递归本来就要算；缓存与归一化的开销见成本表）。两类信号与采样链的关系见 图 1。

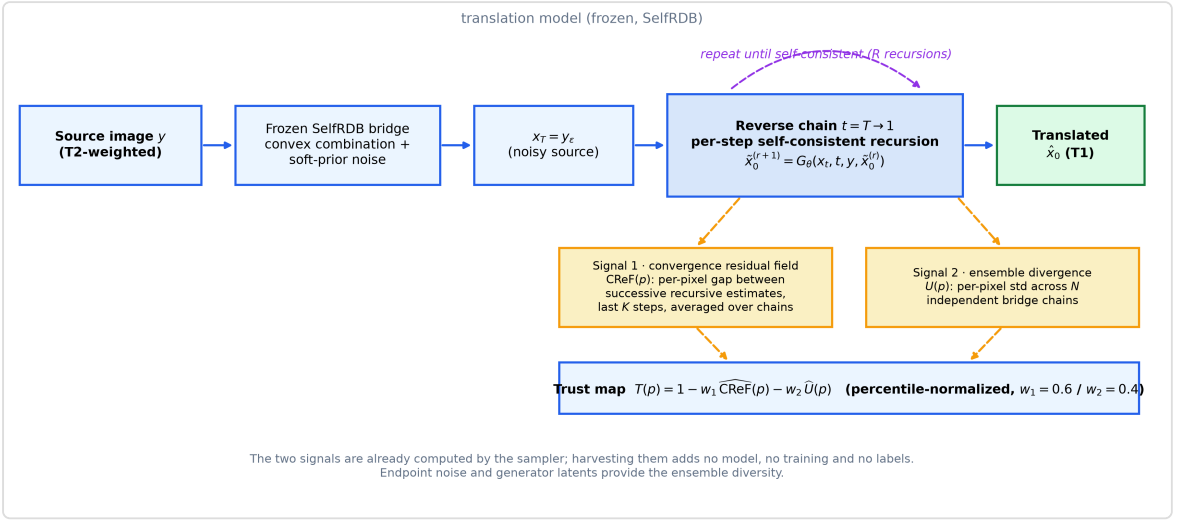


图 1. 方法总览。左：冻结的 SelfRDB 翻译模型（前向桥与含自洽递归的反向链）； 右： 可信度量化层——从递归过程提取收敛残差场（信号一）与多链分歧（信号二）， 融合为逐像素信任图。 两个信号均由采样器本身计算，收割它们不引入任何模型、训练或标注。

3.3 随机桥集成分歧

桥终点 y_ϵ 与生成器内部隐变量 z 使同一输入的两次采样不同。运行 N 条独立链 （不同终点噪声与隐变量）并取逐像素标准差 $U(p) = \mathrm{std}_n\{x_0^{(n)}(p)\}$， 得到第二类信号：跨链不稳定的像素即模型无稳定信念的区域。与 MC-Dropout[19] 或深度集成[20] 不同， 无需注入 dropout、无需训练多个网络；分歧源自桥采样器自身。分割与复原领域的扩散集成工作[23,24] 已证明此类分歧可追踪困难区域； 我们将其与一个非分歧信号（CReF）配对；两者的像素级 Spearman 相关在 §4.4 实测， "互补"以实测相关性为准而非概念断言。

3.4 信任图融合

两图经 99 分位截断的稳健归一化后融合为 $T(p) = 1 - w_1\widehat{\mathrm{CReF}}(p) - w_2\widehat{U}(p)$，默认 $w_1{=}0.6$、 $w_2{=}0.4$。图像级聚合（体区均值）的可行性在 §4.6 作为负结果讨论。 *Trust Score 是由归一化信任图导出的相对风险排序指数，不是经过概率校准的正确率估计*——数值 0.9 不代表输出有 90% 的概率正确。逐片归档（信任图与各步递归统计）随开源代码库提供。

4. 实验

4.1 实验设置

数据集：

IXI[33]：40 名健康被试（T1/T2/PD），按被试 26/6/8 划分、无重叠； 官方协议下 $4,000+$ 配对轴位切片（逐切片统计、官方 mean-norm PSNR/SSIM）。 **BraTS2018**[34]：6 例 HGG 患者（评估 60 个含瘤切片），带真实配准 T2 真值与肿瘤分割，源 FLAIR。**SynthRAD2023 盆腔**[35]： 10 例，中心匹配 T1w$\rightarrow$CT 与 T2w$\rightarrow$CT，各 80 测试切片。

模型：

两个自训 128$\times$128 桥（T2$\rightarrow$T1 与 T1$\rightarrow$T2，30 epochs，单卡 RTX 4060 Laptop 8 GB，配方对齐官方）与两个自训盆腔桥提供定量主干；官方 SelfRDB 权重用于 256$\times$256 演示 与 BraTS FLAIR$\rightarrow$T2 评估。

信任指标口径：

表 2 的翻译质量沿用官方整图 mean-norm 协议以便与文献对照。*全部信任指标* （AUROC、稀疏化、十分位分离、相关）一律在*体掩码内*（源 > 0.02）计算：背景空气 近乎零误差且高信任，与体像素混合会成倍虚高信任指标。我们自己的官方权重运行即为例证： 同一融合信号整图 AUROC 0.90、体区内 0.78，其整图稀疏化增益（$+5.2$ dB）把体区内 有临床意义的增益（$+0.4$ dB）高估了一个数量级。我们项目中所有依赖整图口径的早期结论 均已重评，其中两项被撤回（§§4.8、§4.5）。

指标与掩码定义（冻结于 definitions v1）。

全部信任指标在体掩码内逐片计算：$M = \{\text{源图} > 0.02\}$（源图为逐片 min-max 归一化后的 $[0, 1]$ 图；无形态学后处理——简化协议，阈值 0.01/0.05 的敏感性见 §4.9）。正类=该片体区内 绝对误差前 10% 像素；分数 $= 1 - T(p)$；AUROC 逐片计算后宏平均（另有 pixel-pooled 与 subject-macro 口径，§4.4）； AUPRC 同正类定义并报告实际正类比例。Δ

PSNR@k% = $\mathrm{PSNR}_{\mathrm{retained}(100-k)\%}$ − $\mathrm{PSNR}_{\mathrm{full}}$（mean-norm，data_range=掩码内 归一化 GT 最大值）。十分箱分离 Sep 为比值、ΔMAE 为绝对差——分母趋零时 Sep 只作数量级陈述 （§4.5）。AUSE 为模型与 oracle 风险-覆盖曲线之差的逐片宏平均积分。

伦理。

三个数据集均为公开研究数据集；全部处理本地完成；任何输出不用于临床决策。

4.2 复现危机

崩塌：

官方发布的 IXI 权重在独立制备的 IXI 数据上仅复现 $\sim$15 dB——论文报告 31.56 dB （我们的运行中官方 T1$\rightarrow$T2 权重体区均值 12.98 dB）。在我们系统测试的独立重建预处理 范围内（对齐、切片 z 偏移、强度窗、裁剪、方向），未能复现已发布权重的报告性能； *差异的精确来源尚未确定*——可能包括 checkpoint 版本、训练代码与发布权重不一致、 依赖库差异等，均已记录在复现排查表中（docs/18，区分已核查/未核查与证据）。伴随的 SynDiff 发布版亦被社区独立报告类似问题。失效形态不可见：官方输出是平滑、貌似合理的图像而非噪声——但结构上是错的（体区 NCC 0.41，见下）。

信任层在崩塌面前看到什么、看不到什么：

一个自然的期望是采样器原生信号能"察觉"基座模型失效。我们直接测试了它，答案构成本文最重要的阴性结果。在崩塌的官方模型上，信任图不放警报——平均信任 94.2/100、 低信任占比 5.9%（低于我们健康的自训模型）、20 片测试全部 PASS。且该崩塌*不是* 良性的光度偏移：体区 NCC 0.41、SSIM 29%，用真值拟合的线性强度校正后 PSNR 仍 12.3 dB——官方模型在合成*结构上错误但内部自洽*的解剖。采样器对自己的错误输出 高度自信，因此度量自洽性的 CReF 与集成分歧全部失明——正如肿瘤分析在像素级预言的那样， 现在模型级复现了一遍。部署教训：*免训练内部信号无法察觉"自信地犯错"的基座模型*。 它们补充、但不能替代对真值的外部验证；从未见过基座模型失败的守卫层，不可被信任去识别失败 （图 2）。

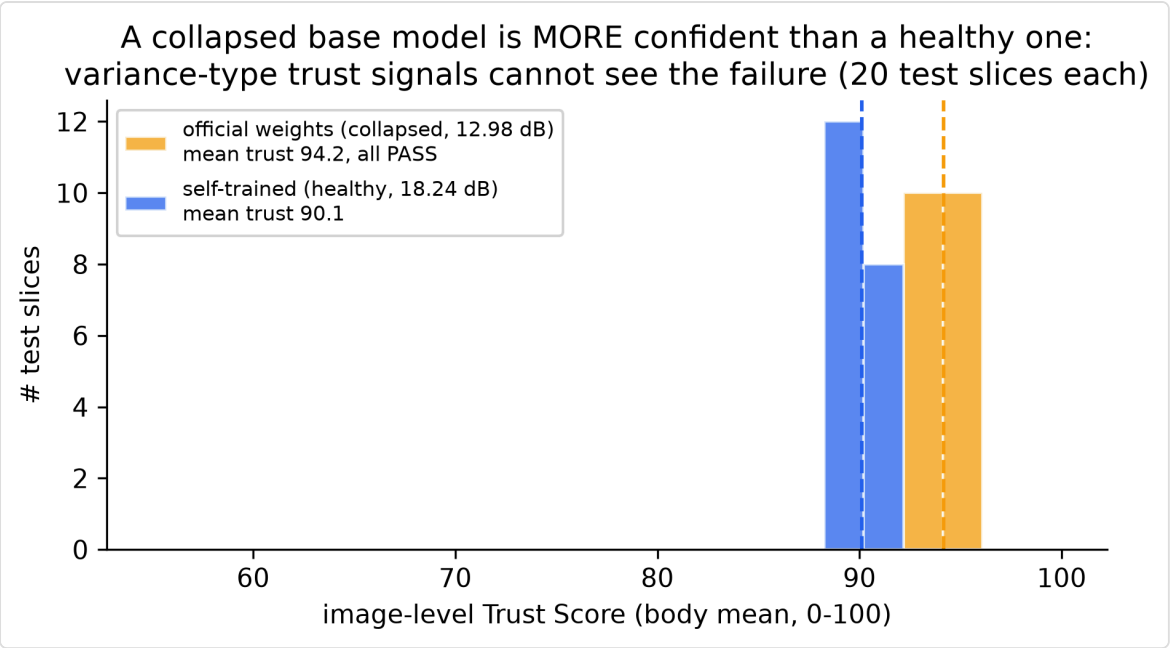


图 2. 崩塌基座模型 vs 健康模型的图像级信任分布（各 20 片测试切片，seed 2026）。 结构性崩塌的官方权重（12.98 dB）获得的信任（均值 94.2，全部 PASS）反而高于健康的 自训模型（90.1）——方差型信号对"自信地犯错"失明。

4.3 翻译质量

表 2. 主结果（官方整图 mean-norm PSNR/SSIM 协议）。"校正"列去除全局线性强度失配， 其参数由真值估计；它是*误差分解诊断*而非方法指标——raw 列才是诚实的工作点。 IXI：自训 128×128（各 60 测试切片）。盆腔：自训，各 80 测试切片。BraTS：官方 FLAIR→T2 权重， 60 个含瘤切片。

数据集	方向	PSNR (dB)	SSIM (%)	NCC	校正 PSNR
IXI（论文值[3]）	T2→T1	31.56	95.65	–	–
IXI，本文	T2→T1	19.81±1.10	71.0±6.6	0.884	31.74
IXI，本文	T1→T2	20.44±1.16	80.4±4.1	0.905	32.52
盆腔，本文	T1w→CT	24.36±2.92	81.6±4.8	0.962	–
盆腔，官方	T1w→CT	21.24±2.42	64.3±6.0	0.936	–
盆腔，本文	T2w→CT	23.13±0.83	74.5±2.7	0.961	–
盆腔，官方	T2w→CT	19.04±0.73	57.3±2.9	0.893	–
BraTS2018，官方	FLAIR→T2	24.06±1.62	87.4	0.944	–

表 2 报告翻译质量。IXI 上误差分解显示，128×128 自训模型的内容保真度 已达到论文设定：去除全局线性强度失配后 PSNR 达 $31.74/32.52$ dB （T2→T1/T1→T2），对照论文 31.56 dB；raw 差距归因于该偏移与缩减的训练预算—— 我们强调校正列使用真值估计的参数、仅作诊断。自训盆腔桥以真实 CT 真值超过官方权重 $+3.1/+4.1$ dB。肿瘤患者上，官方 FLAIR→T2 权重对真实配准 T2 达 24.1 dB （整图口径；体区内 18.3 dB）——本管线在*病理*数据上完成了定量验证。

4.4 信任定位、UQ 基线与失效边界

表 3. 体掩码口径下的不确定性-质量对照（IXI 测试集，每方向 60 切片，seed 2026）。 **上：**自训 128×128 模型（定量主干）；所有分歧基线与本文集成同预算 （40 次生成器前传）；CReF（N=1）单链仅 10 次（*零额外成本*）。Sep 为最不可信与 最可信十分位平均误差之比的跨切片中位数；自训 T1→T2 的最可信十分位误差近零， Sep 只作数量级陈述。**下：**官方权重上同一协议，信号排序改变且 T2→T1 全盲。 各行性质：随机=对照；梯度/输入噪声/TTA=等预算基线；CReF/仅集成/融合=本文方法。

	T1→T2（自训）			**T2→T1（自训）**		
信号	AUROC	ΔPSNR@20%	Sep	AUROC	ΔPSNR@20%	Sep
随机（对照）	0.498	≈0	1.0	0.501	≈0	1.0
梯度	0.225	-0.45	0.54	0.475	-0.55	0.51
输入噪声分歧	0.861	$+1.47$	65	0.739	$+0.97$	3.0
TTA 分歧	0.820	$+1.33$	6.3	0.711	$+0.79$	1.9
CReF 单链（N=1，无额外前传）	0.880	$+2.28$	103	0.792	$+1.51$	2.8
仅集成（N=4）	0.897	$+2.34$	159	0.806	$+1.63$	3.8
融合（本文）	**0.900**	$\mathbf{+2.67}$	**182**	**0.816**	$\mathbf{+1.85}$	**3.7**
官方权重上同一协议（N=4 融合）：						
融合（官方）	0.783	$+0.37$	–	0.465	$+0.21$	–
TTA（官方）	**0.808**	$+0.70$	–	0.482	$+0.95$	–
全部分歧信号（官方，T2→T1）	–	–	–	0.465–0.505（随机水平）		

表 3 承载两个信息。**自训模型上**，本文融合信号 AUROC $0.900/0.816$，稀疏化增益 $+2.67/+1.85$ dB。配对患者级 bootstrap（$B=5000$， 8 被试）显示：融合相对仅集成的 Δ AUROC 为 $+0.004$（95% CI $[-0.001, 0.008]$， *含 0*——T1→T2 上不显著）与 $+0.010$（CI $[0.005, 0.015]$，T2→T1 上显著）； 而融合相对全部等预算基线（TTA $-0.082/-0.107$、噪声 $-0.041/-0.078$、梯度）差异 显著且幅度大。单链 CReF（零额外成本）已达 $0.880/0.792$——四分之一预算拿到大部分 价值；CReF 的论据是成本而非精度。**官方权重上**，排序改变且 T2→T1 方向整体 崩塌：所有分歧信号——我们的与全部基线的——*系统性低于随机*（融合 CI $[0.442, 0.485]$， 上界 < 0.5），因为该模型残差误差由细纹理主导、一切分歧度量都无法追踪。*同一方向*、 *同一协议*、*两个模型*、*相反结论*：失效边界是（模型, 方向）对的属性而非信号的属性，这正是 我们建议部署前按（模型, 方向）逐一验证不确定性信号的原因（§5）。我们还测试了 CReF 触发的路由策略 （不确定区域交 TTA 复核）以期低成本逼近满预算 TTA 质量；自训模型上曲线平坦——纯 CReF （预算 10，0.880）已全面优于满预算 TTA（0.820）——路由在该模型上没有增益， 进一步确认信号排序的模型相关性。图 3 给出典型切片的六联可视化： 信任图与真实误差的空间对应关系是全部定量结论的直觉基础。

4.5 误差排序与十分位分离

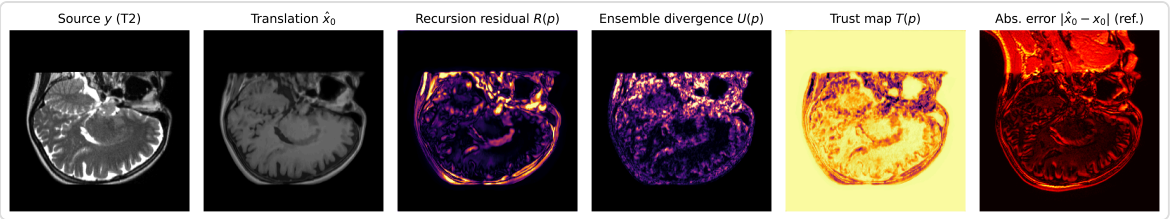


图 3. 典型切片六联可视化（T2→T1，自训模型）：源图、合成图、CReF、集成分歧、 信任图与真实绝对误差（仅评估用）。信任图与误差图的空间对应关系是本文定性证据的核心： 亮=可信、暗=可疑。测试集 60 片中逐片模式一致。

体区内，最不可信十分位携带 $194\times$（T1→T2，中位；其最高三箱误差接近零， 倍数只作数量级陈述）、$4.0\times$（T2→T1）与 $2.1\times$（BraTS）的最可信十分位 平均绝对误差。这些分离远小于整图口径显示的 35–$73\times$——后者由空气/体区对比主导。信任图应作为*体区内的排序*使用， 而非绝对误差量级（图 4）。

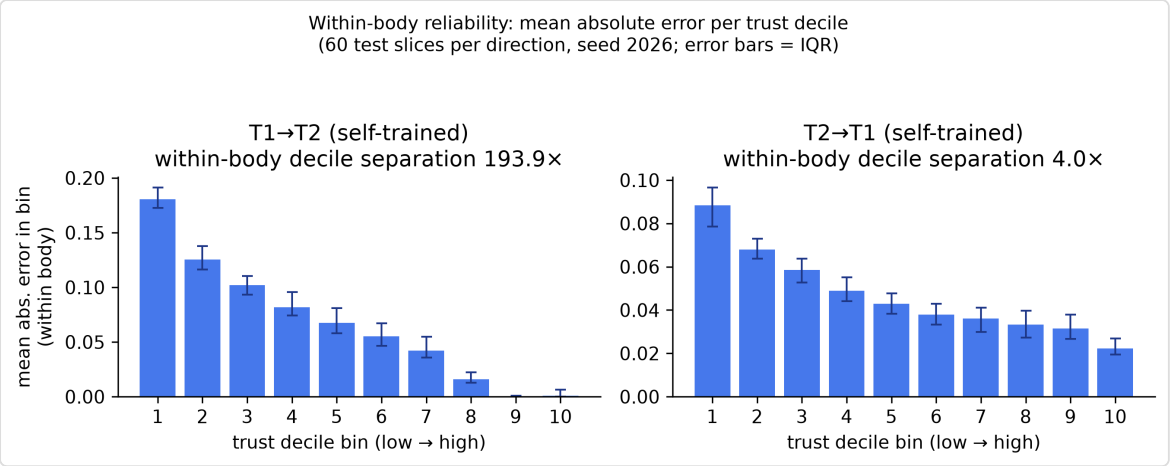


图 4. 体区口径可靠性：按信任十分箱后的各箱平均绝对误差（每方向 60 测试切片， seed 2026，误差棒为四分位距）。两方向均近单调递减；体区口径下分离幅度远小于 整图口径（历史值 35–73× 系空气/体区对比主导，已撤回，不作为方法指标）。 最高三箱误差接近零，Spearman 在零值段不敏感。

4.6 图像级 QC 操作点

图像级是本层最薄弱处，我们量化而非回避。跨三个队列（IXI 双方向各 60 片；BraTS 60 片）， 切片级Trust Score（体区均值，0–100）与切片质量（体区 PSNR）相关微弱：Pearson $r = +0.47$（T1→T2，自训）、$r = +0.26$（T2→T1，自训）、$r = -0.10$（BraTS，官方）——信号有效的模型上方向正确，信号失效的模型上相关性消失。出厂阈值同样与实际分数分布错位：PASS$\geq$75 拦截 88% 汇总切片，REJECT<55 仅覆盖 3%；最优汇总工作点上也只能以 9% 覆盖换取 29% 精确率 （对质量下四分位）。 因此我们给出比"阈值需重调"更强的结论：*全局标量信任分根本不应作为医学图像翻译的 QC 门*。切片间解剖差异之大，使任何体区均值分数都无法在队列内分离好坏。我们建议社区 把像素/区域级信任证据（信任图、低信任区域清单）标准化为人工复核依据，任何图像级门控 ——包括我们的——至多作为分诊启发式。

4.7 边界实验

七项受控实验划定了该层在此数据规模上能做什么、不能做什么： (1) *可学习聚合*：16 特征 logistic/GBDT 在验证集训练，T2→T1 微升（$+0.010$ AUROC）而 T1→T2 退化（-0.03）

——过拟合 6 被试验证集；(2) *图像级回归*：16 特征岭回归预测图像 PSNR 差于基线信任均值（0.32–0.33 对 0.38–0.40）；(3) *自适应重采样*与 (4) *往返一致信号*：零质量增益（-0.016 dB 与 AUROC 0.503）而成本 $+35$–75%——与集成均值饱和一致；(5) *强度调和*：事后分位/仿射匹配使 raw PSNR 下降（-0.8/-0.9 dB），因为无真值 时逐片强度偏移不可盲估；(6) \emph官方权重 T2$\rightarrow$T1 信号失效}（§§4.4）：该模型残差误差纹理主导时 所有分歧信号接近或低于随机，而同方向自训模型正常（0.816）——失效定位于模型而非任务；(7) *语义代理信号无互补*：源-合成块级归一化互信息与梯度方向一致性仅达 AUROC 0.42–0.67（分歧信号 0.82–0.90），与分歧组合亦无增益——与*源图*的结构一致 是比采样器内部分歧更弱的误差代理。以上全部作为阴性结果完整报告：在 40 被试规模下， 像素级信任图是本文实验范围内得到相对稳定证据支持的输出形式，其临床效用 尚未验证；重开可学习聚合需要大得多的验证集（估计 $\geq$20 被试，待验证）。

4.8 肿瘤区域分析

BraTS 队列（官方 FLAIR$\rightarrow$T2 权重，60 含瘤切片，体区口径）：(i) 瘤内像素误差为瘤外 $1.60\times$（90% 切片方向一致），合成风险确实向病灶集中；(ii) 信任图把高误差十分位定位到 AUROC 0.911 ± 0.037、20% 稀疏化增益 $+3.12$ dB——口径修正后信任信号在该模型上依然成立； 但 (iii) 我们*撤回*早先的结论：低信任*不*定位肿瘤组织本身（对分割的体区 AUROC 仅 0.51 ± 0.10；旧值 0.871 系整图空气负例伪影），且瘤内平均信任*略高于*瘤外 （0.772 对 0.727）。被标记区域指示模型对合成不确定的位置，不是病灶所在。这一边界不是实现缺陷， 而是方差型信号的原理性盲区。教训超出本文方法：像素方差式 UQ 度量的是*合成过程的方差*，不是内容的*临床显著性*—— 模型可以对病理上错误的合成高度自信（且高度自洽）。任何面向临床的 UQ 层都必须对照 病理标注审计，而不能只对照误差图（图 5）。

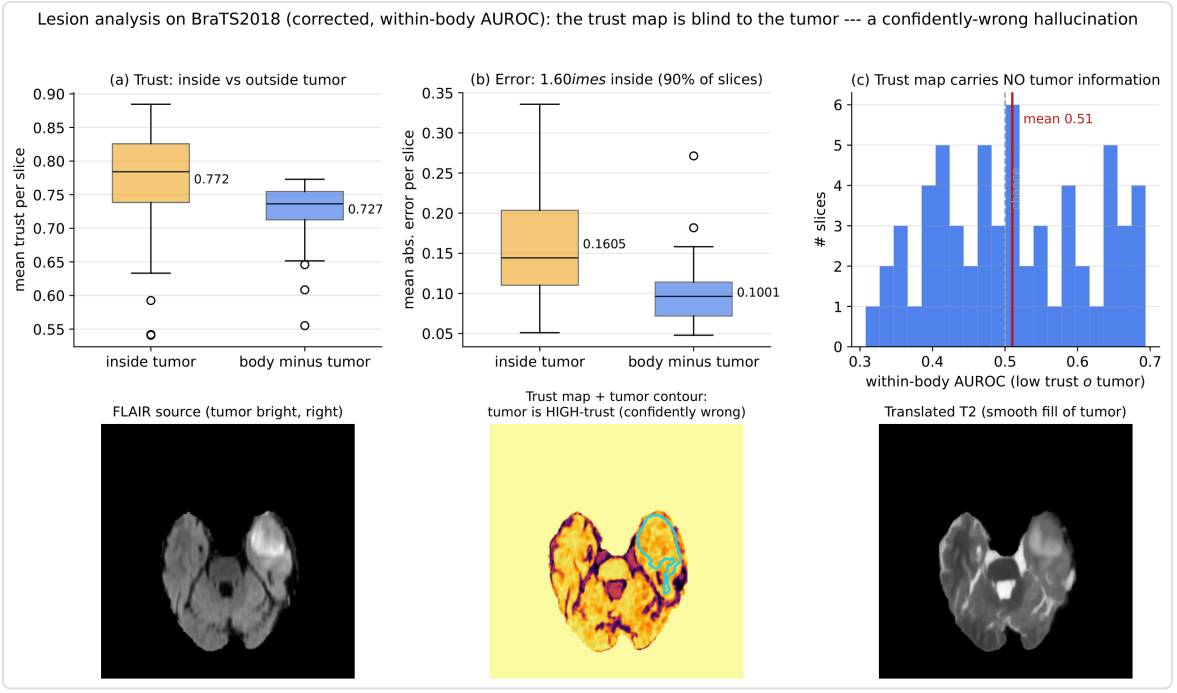


图 5. 病灶盲区（修正版，BraTS2018，60 个含瘤切片，体掩码内口径）。 (a) 瘤内/体（非瘤）逐片平均信任；(b) 逐片平均绝对误差——瘤内为瘤外的 1.60 倍；(c) 体掩码内低信任指示肿瘤的 AUROC 分布——均值 0.51，等于随机水平（红线）；(d–f) 案例切片：FLAIR（瘤区亮）、信任图+瘤轮廓（瘤区为高信任）、翻译结果。 模型在均质亮区自洽地插值出错误内容（偏差型幻觉），方差型信号不可见。

4.9 压力测试：输入退化与跨机构迁移

输入退化：

我们沿三条轴退化输入——高斯模糊（$\sigma \in \{0.5, 1, 2\}$）、高斯噪声 （$\sigma \in \{0.01, 0.03, 0.06, 0.1\}$）、水平错位（2–8 px）——IXI 测试 30 片/剂量。 翻译质量轻微恶化（体区 PSNR 最差剂量 $12.9 \rightarrow 11.8$ dB；官方 T1→T2 权重； 本节信任值为体区均值，聚合口径与 §4.2 的整图信任分不同）。信任机制的响应不对称而有 教学意义：输入侧 Mahalanobis 距离（开源输入防御层的域外评分，此处仅作测量仪器）对模糊（$2.9 \rightarrow 15.0$）与噪声（$\rightarrow 9.3$） 剂量敏感，对小幅错位无感（$\rightarrow 2.9$）；信任图完全不对退化输入报警——中等模糊反而 *抬高*平均信任（$0.63 \rightarrow 0.70$，更平滑的输入让采样器更易自洽）——体区定位 AUROC 随剂量衰减（噪声 $0.79 \rightarrow 0.70$；错位 $\rightarrow 0.67$）。这里"知道自己不知道"由输入侧 Mahalanobis 检测承担而非信任图；错位检测仍未解决（§5 讨论）。

跨机构迁移：

对采样器原生信任证据最强烈的外部质疑是它可能锁死在训练队列上。我们在两个从未见过的患者集合上以完全相同的管线（官方 FLAIR→T2 权重、相同协议）重评：六个与参照队列 同系列的同源留出患者（患者级泛化），与六个由不同机构制备的 CBICA 验证受试者 （机构级泛化），各 120 片。信任定位*迁移成立*：AUROC 0.863 ± 0.155（留出患者） 与 0.950 ± 0.021（跨机构），对照参照队列 0.911 ± 0.037；稀疏化增益 $+2.78$ 与 $+3.12$ dB。保留注意项——我方预处理配方一致、每组仅六例——但方向明确：在该队列族内， 这些信号不是"见过患者"的伪影。

5. 讨论

有效与失效条件：

信任层有效的条件：残差误差呈空间结构、基座模型未崩塌、评估在体区内进行。 失效的条件：纹理主导的误差、偏差型幻觉（病灶）、模型级崩塌（§§4.2）、 图像级聚合（§4.6）。带着这张清单，下文逐条展开。

质量与信任校准可分离：

自训盆腔桥 PSNR 高于官方权重 $+3.1/+4.1$ dB，但信号排序随模型改变（表2 上/下面板）； 最尖锐的例子是官方 T2→T1 权重——它的信任信号完全无信息。模型可以准确而其不确定性 无信息：当残差误差缺乏分歧度量所响应的空间结构时。不确定性信号必须按（模型, 方向）对 逐一验证后才可部署——这一结论由我们自己的阴性结果落地。

口径陷阱：

在图像存在"可信低误差背景"的翻译设定中——绝大多数医学图像翻译场景皆如此—— 整图口径的逐像素信任指标会系统性乐观。我们建议体区口径成为该领域不确定性评估的标准实践， 并公开撤回轨迹（docs/18 与修正脚本）作为"这很容易做错"的证据——我们就做错过。

两层安全架构的定位。

本文的发现把系统拆成两层：*输入完整性监测*（域外检测、强度分布异常、模糊/噪声/ 错位——输入侧 Mahalanobis 距离已覆盖其中部分）与*采样器原生信任估计* （CReF+集成分歧的像素级排序）；两者之外，自信的结构性幻觉与图像级质量退化 必须由外部验证与人工复核兜底。TrustBridge 不是完整的医学图像安全系统， 而是可信工作流中的内部信号评估层。

局限性：

(1) 信任图标记*不可靠*区域而非*错误*区域：自信合成的幻觉对它不可见—— 且这种盲区延伸到模型级：自信地犯错的崩塌基座模型获得 PASS（平均信任 $94/100$， §§4.2）。 (2) 可学习聚合过拟合 6 被试验证集；重开需要大得多的验证集（估计 $\geq$20 被试，待验证）。 (3) 输入级错误（如源模态用错）超出采样器原生信号的感知范围，需要独立的输入防御层 ——我们已将其开源实现于代码库，但超出本文论述范围。 (4) 图像级 QC 与肿瘤定位在此规模仍未解决；信任图还不响应输入退化——模糊反而抬高它 （§§4.9）——退化输入检测由输入侧 Mahalanobis 检测承担，小幅错位两者皆盲。 (5) 全部输出为研究演示，不得指导临床决策。

6. 结论

我们把最先进扩散桥采样器中被丢弃的内部量构建了像素级的免训练可信度量化层， 并施加了比原计划严苛的验证：体掩码口径、等预算基线、逐队列操作点分析。幸存下来的是 一幅清晰而有边界的图景：在误差呈空间结构的模型上（自训 T1$\rightarrow$T2/T2$\rightarrow$T1；官方权重 的肿瘤数据），免训练信号能很好定位不可靠区域（AUROC 0.82–0.95），CReF 以无额外前传的方式供给其中大部分价值；在纹理主导的误差上，这些信号——以及我们试过的所有基线——集体失明。 更广的方法论启示有二：生成采样器算出的证据多于它用掉的，收割这些证据能把合成引擎变成 可评估信任的系统；但图像翻译的不确定性主张必须在体区内、对照廉价基线、按（模型, 方向） 逐一评估，否则必然被高估。未来工作将在更大被试规模上检验是否可重开可学习聚合、扩展至 256$\times$256 模型，并引入放射科医生反馈。

致谢：

感谢 SelfRDB 作者（Bilkent ICON Lab）以 MIT 许可发布代码与权重，感谢 IXI、BraTS、SynthRAD 各联盟提供公开数据。本工作为学生研究演示，输出不得用于临床决策。

References

1. Ho et al. (2020). Denoising Diffusion Probabilistic Models. *Advances in Neural Information Processing Systems*.
2. Nichol et al. (2021). Improved Denoising Diffusion Probabilistic Models. *International Conference on Machine Learning*.
3. Arslan et al. (2025). Self-Consistent Recursive Diffusion Bridge for Medical Image Translation. *Medical Image Analysis*.
4. Tivnan et al. (2024). Hallucination Index: An Image Quality Metric for Generative Reconstruction Models. *Medical Image Computing and Computer Assisted Intervention (MICCAI)*.
5. Zhu et al. (2017). Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks. *IEEE International Conference on Computer Vision*.

6. Isola et al. (2017). Image-to-Image Translation with Conditional Adversarial Networks. *IEEE Conference on Computer Vision and Pattern Recognition*.
7. Dar et al. (2019). Image Synthesis in Multi-Contrast MRI with Conditional Generative Adversarial Networks. *IEEE Transactions on Medical Imaging*.
8. Dalmaz et al. (2022). ResViT: Residual Vision Transformers for Multi-Modal Medical Image Synthesis. *IEEE Transactions on Medical Imaging*.
9. Özbey et al. (2023). Unsupervised Medical Image Translation with Adversarial Diffusion Models. *IEEE Transactions on Medical Imaging*.
10. Korkmaz et al. (2025). I2I-Galip: Unsupervised Medical Image Translation Using Generative Adversarial CLIP. *Medical Imaging with Deep Learning (MIDL)*.
11. Song et al. (2020). Score-Based Generative Modeling through Stochastic Differential Equations. *arXiv:2011.13456*.
12. Song et al. (2019). Generative Modeling by Estimating Gradients of the Data Distribution. *Advances in Neural Information Processing Systems*.
13. Liu et al. (2023). I2SB: Image-to-Image Schrödinger Bridge. *arXiv:2302.05872*.
14. Chung et al. (2023). Direct Diffusion Bridge Using Data Consistency for Inverse Problems. *arXiv:2305.19809*.
15. Su et al. (2023). Dual Diffusion Implicit Bridges for Image-to-Image Translation. *arXiv:2203.08382*.
16. Kim et al. (2024). Unpaired Image-to-Image Translation via Neural Schrödinger Bridge. *International Conference on Learning Representations*.
17. Delbracio et al. (2023). Inversion by Direct Iteration: An Alternative to Denoising Diffusion for Image Restoration. *Transactions on Machine Learning Research*.
18. Zhang et al. (2025). Diffusion Bridge Models for 3D Medical Image Translation. *arXiv:2504.15267*.
19. Gal et al. (2016). Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning. *International Conference on Machine Learning*.
20. Lakshminarayanan et al. (2017). Simple and Scalable Predictive Uncertainty Estimation Using Deep Ensembles. *Advances in Neural Information Processing Systems*.
21. Ayhan et al. (2018). Test-Time Data Augmentation for Estimation of Heteroscedastic Aleatoric Uncertainty in Deep Neural Networks. *Medical Imaging with Deep Learning (MIDL)*.
22. Kendall et al. (2017). What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision? *Advances in Neural Information Processing Systems*.
23. Wolleb et al. (2022). Diffusion Models for Implicit Image Segmentation Ensembles. *Medical Imaging with Deep Learning (MIDL)*.
24. Osuna-Vargas et al. (2024). Denoising Diffusion Models for High-Resolution Microscopy Image Restoration. *arXiv:2409.12078*.
25. Song et al. (2024). Self-Consistent Nested Diffusion Bridge for Accelerated MRI Reconstruction. *arXiv:2412.09998*.
26. Oliveras et al. (2026). MUMINS: Metadata-Conditioned Uncertainty-Aware Medical Image Next-State Synthesis. *arXiv:2609.17169*.
27. Jin et al. (2026). Measurement Geometry and Design for Trustworthy Generative Inverse Problems. *arXiv:2606.02309*.
28. Cardoso et al. (2023). RAISE – Radiology AI Safety, an End-to-End Lifecycle Approach. *arXiv:2311.14570*.
29. Russe et al. (2026). AI-RADS: A Framework for Assessment of Artificial Intelligence Output in Radiology: Development and Multireader Evaluation. *Investigative Radiology*.

30. Chung et al. (2026). CRAFT: Clinical Reward-Aligned Finetuning for Medical Image Synthesis. *arXiv preprint arXiv:2605.12650*.
31. Susladkar et al. (2025). ViCTr: Vital Consistency Transfer for Pathology-Aware Image Synthesis. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*.
32. Li et al. (2025). Denoising Diffusion Wavelet Models for Zero-shot Medical Image Translation. *Knowledge-Based Systems*.
33. Imperial College London (2008). IXI Dataset.
34. Menze et al. (2015). The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS). *IEEE Transactions on Medical Imaging*.
35. Thummerer et al. (2023). SynthRAD2023 Grand Challenge Dataset: Generating Synthetic CT for Radiotherapy. *Medical Physics*.